🧠 القسم الأول: اختيار من متعدد (٢٠ سؤال)

الهدف الأساسي من NLP هو:

أ) تحليل الصور

ب) فهم اللغة البشرية

ج) تحسين الشبكات

د) ضغط البيانات

Tokenization تعني:

أ) ترجمة النص

ب) تقسيم النص

ج) ضغط النص

د) حذف الكلمات

Stop Words هي:

أ) كلمات نادرة

ب) كلمات شائعة قليلة القيمة

ج) كلمات تقنية

د) كلمات طويلة

TF-IDF يستخدم لـ:

أ) الترجمة

ب) تمثيل النص

ج) تصنيف الصور

د) ضغط البيانات

Bag of Words:

أ) يحافظ على ترتيب الكلمات

ب) يهمل الترتيب

ج) يستخدم الشبكات العصبية

د) يعتمد على السياق

أي نموذج يعتمد على السياق؟

أ) TF-IDF

ب) Bag of Words

ج) BERT

د) Count Vector

Lemmatization:

أ) تقطيع النص

ب) تحويل الكلمة لأصلها

ج) حذف الكلمات

د) ضغط النص

Word2Vec ينتج:

أ) صور

ب) متجهات

ج) جمل

د) قواعد

أي خوارزمية مناسبة لتصنيف النص؟

أ) KNN

ب) Naive Bayes

ج) Decision Tree

د) جميع ما سبق

NER تعني:

أ) تحليل المشاعر

ب) التعرف على الكيانات

ج) الترجمة

د) تصنيف النص

Overfitting يعني:

أ) نموذج ضعيف

ب) نموذج يحفظ البيانات

ج) نموذج سريع

د) نموذج بسيط

Underfitting يعني:

أ) نموذج بسيط جدًا

ب) نموذج معقد

ج) نموذج دقيق

د) نموذج سريع

Embedding هو:

أ) صورة

ب) تمثيل رقمي للكلمات

ج) نص

د) خوارزمية

Language Model هدفه:

أ) الترجمة

ب) توقع الكلمة التالية

ج) ضغط النص

د) حذف الكلمات

Transformer يعتمد على:

أ) CNN

ب) RNN

ج) Attention

د) KNN

Attention يساعد في:

أ) حذف الكلمات

ب) التركيز على الكلمات المهمة

ج) ضغط النص

د) تحويل النص

POS Tagging:

أ) ترجمة

ب) تحديد نوع الكلمة

ج) حذف الكلمات

د) تحليل الصور

أي مما يلي Unsupervised؟

أ) Classification

ب) Clustering

ج) Regression

د) Decision Tree

Cosine Similarity تستخدم لـ:

أ) الترجمة

ب) قياس التشابه

ج) تصنيف الصور

د) ضغط النص

GPT هو:

أ) نموذج لغة

ب) خوارزمية تصنيف

ج) قاعدة بيانات

د) نظام تشغيل

ما هو Byte Pair Encoding (BPE)؟

أ) خوارزمية ضغط نصوص

ب) طريقة Tokenization

ج) نموذج لغة

د) خوارزمية تصنيف

Subword Tokenization تستخدم لـ:

أ) حذف الكلمات

ب) التعامل مع الكلمات النادرة

ج) ترجمة النص

د) ضغط البيانات

ما هو n-gram؟

أ) نموذج عميق

ب) تسلسل من n كلمات

ج) خوارزمية

د) قاعدة بيانات

Bigram يعني:

أ) كلمة واحدة

ب) كلمتين

ج) ثلاث كلمات

د) أربع كلمات

Trigram يعني:

أ) كلمتين

ب) ثلاث كلمات

ج) أربع كلمات

د) خمس كلمات

Perplexity تستخدم لـ:

أ) قياس جودة النموذج اللغوي

ب) ضغط النص

ج) حذف الكلمات

د) تصنيف الصور

BLEU Score يستخدم في:

أ) تصنيف النص

ب) الترجمة الآلية

ج) تحليل المشاعر

د) clustering

ROUGE يستخدم في:

أ) الترجمة

ب) التلخيص

ج) التصنيف

د) التعلم العميق

Seq2Seq Model يستخدم في:

أ) التصنيف

ب) الترجمة

ج) clustering

د) PCA

Encoder يقوم بـ:

أ) توليد النص

ب) تمثيل الإدخال

ج) حذف الكلمات

د) ضغط الصور

Decoder يقوم بـ:

أ) تحليل الصور

ب) توليد النص

ج) حذف الكلمات

د) تصنيف البيانات

Masked Language Model:

أ) يتوقع الكلمة المحذوفة

ب) يترجم النص

ج) يصنف النص

د) يضغط البيانات

Autoregressive Model:

أ) يتوقع كل الكلمات دفعة واحدة

ب) يتوقع الكلمة التالية

ج) لا يستخدم سياق

د) نموذج ثابت

Transformer يتكون من:

أ) Encoder فقط

ب) Decoder فقط

ج) Encoder و Decoder

د) CNN

Self-Attention:

أ) يعتمد على الصور

ب) يربط الكلمات ببعضها

ج) يحذف الكلمات

د) يضغط النص

Positional Encoding يستخدم لـ:

أ) حذف الترتيب

ب) تمثيل ترتيب الكلمات

ج) ضغط النص

د) حذف الكلمات

Fine-tuning يعني:

أ) تدريب من الصفر

ب) تحسين نموذج جاهز

ج) حذف البيانات

د) ضغط النموذج

Transfer Learning:

أ) تدريب جديد

ب) نقل المعرفة

ج) حذف البيانات

د) تصنيف الصور

Zero-shot Learning:

أ) تدريب كامل

ب) بدون تدريب مباشر

ج) تعلم عميق

د) clustering

Few-shot Learning:

أ) بيانات كثيرة

ب) بيانات قليلة

ج) بدون بيانات

د) ضغط البيانات

✍ القسم الثاني: أسئلة نظرية (١٥ سؤال)

س ١؟

اشرح مفهوم Tokenization مع مثال؟

Tokenization:- هي عملية تقسيم الجملة الي عدد من أجزاء(الكلمات).

و هي قائمة فصل الكلمات من الجمل بحيث تكون كل كلمة وحدها وهناك نوعين منها

Word tokenizer :- (تقطيع الكلمات):-فصل الجملة إلى كلمات منفصلة.

sentence tokenizer:- (تقطيع الجمل):- فصل النص الطويل أو الفقرة إلى جمل مستقلة بناءً على علامات الترقيم(مثل النقطة أو علامة الاستفهام).

وأيضا يمكنك تقسيم الكلمة حسب (جملة كاملة , أجزاء من الكلمة , الحرف)

المثال :- " الذكاء الاصطناعي يغير العالم. هل أنت مستعد؟"

النتيجة:-

١- الذكاء الاصطناعي يغير العالم.

٢- هل أنت مستعد؟

س٢ ؟

ما الفرق بين Stemming و Lemmatization؟

Stemming:- هي عملية قص الحوف الزائدة في الكلمات.

طريقتها:- تقص الحروف بشكل آلي دون النظر لسياق الكلمة أو معناها.

النتيجة:- قد تنتج كلمات ليس لها معنى لغوي (مثل قص "مكتبة" لتصبح "مكتب").

Lemmatization:- هي عملية إرجاع الكلمة إلى أصلها اللغوي (Lemma)بناءً على المعجم والقواعد النحوية.

طريقتها:- هي عملية أذكى؛ فهي تحلل الكلمة وتعرف نوعها (اسم، فعل، فاعل) لتصل إلى الجذر الصحيح.

النتيجة :- دائماً ما تنتج كلمة صحيحة لغوياً ولها معنى في القاموس.

س٣؟

ما هو Bag of Words؟ وما عيوبه؟

ماهو **Bag of Words:-** هو نموذج بسيط جداً يُستخدم في معالجة اللغات الطبيعية (NLP) لتحويل النص إلى بيانات رقمية(Vectors).

وما عيوبه؟

١- فقدان الترتيب والسياق

٢- مشكلة الأبعاد الضخمة

٣- تجاهل المعنى والمترادفات

س٤؟

اشرح TF-IDF وكيف يعمل.

TF-IDF :- هي اختصار Term Frequency-Inverse Document Frequency وهي تعتمد على قيمتين هامتين هما

أولا Term Frequency اي معدل تكرار الكلمة المطلوبة

ثانيا Inverse Document Frequency الذي يشير الي مدي ندرة او شيوع هذه الكلمة .

فكرتها الأساسية هي " الكلمة تكون مهمة إذا تكررت كثيراً في مستند واحد، بشرط ألا تتكرر في جميع المستندات الأخرى".

كيف تعمل:-

يتكون المقياس من جزأين يتم ضربهما في بعضهما:

١- تردد الكلمة(Term Frequency – TF)

يقيس كم مرة ظهرت الكلمة في المستند الحالي.

$$TF(t,d) = \frac{\text{عدد مرات ظهور الكلمة t في المستند d}}{\text{إجمالي عدد الكلمات في المستند d}}$$

المنطق :كلما زاد التكرار، زادت الأهمية المبدئية. المنطق :كلما زاد التكرار، زادت الأهمية المبدئية.

٢- تردد المستند العكسي(Inverse Document Frequency - IDF)

يقيس مدى "ندرة" الكلمة عبر جميع المستندات.

$$IDF(t,D) = \log\left(\frac{\text{إجمالي عدد المستندات D}}{\text{عدد المستندات التي تحتوي على الكلمة t}}\right)$$

المنطق :الكلمات الشائعة جداً (مثل: "في"، "على"، "من") ستظهر في كل المستندات، لذا سيكون الـ IDF الخاص بها قريباً من الصفر مما يقلل من أهميتها. أما الكلمات المتخصصة (مثل: "خوارزمية"، "Stemming") فستأخذ قيمة IDF عالية لأنها نادرة.

س٥؟

ما هي Word Embeddings؟

مصفوفة للكلمات والتي تقوم بتمثيل قيم خاصة لكل الكلمة , لتحديد معناها, و لمعرفة مدي تقارب او ابتعاد هذه الكلمة عن باقي الكلمات .

س٦؟

ما الفرق بين Word2Vec و GloVe؟

وجه المقارنة	Word2Vec	GloVe
المطور	Google	Stanford
الآلية	تنبؤ محلي (Local Context)	إحصاء كلي (Global Statistics)
الرياضيات	الشبكات العصبية (Neural Networks)	تحليل المصفوفات (Matrix Factorization)
القوة	ممتاز في العلاقات التناظرية (Analogies)	ممتاز في فهم السياق العام للمعنى

س٧؟

ما هي التحديات في اللغة العربية؟

١- الاختلاف الكبير في اللهجات حتى في نفس اللغة.
٢- التقطيعات غير الصحيحة في جمل
٣- التعبيرات المجازية
٤- المصطلحات الجديدة
٥- الاستخدامات الساخرة للكلمات
٦- كلمات متعددة الاستخدامات والمعاني
٧- الحقائق التاريخية
٨- صعوبة تحديد المصطلحات الخاصة

س٨؟

اشرح مفهوم Language Modeling:-

بساطة، نموذج اللغة هو نموذج رياضي مصمم لتقدير احتمالية ظهور سلسلة من الكلمات. وظيفته الجوهرية هي التنبؤ بالكلمة التالية بناءً على الكلمات التي سبقتها.

أنواع نماذج اللغة (تطورها التاريخي)نوعين هما

١- النماذج الإحصائية التقليدية(N-gram Models)
٢- النماذج العصبية والحديثة(Neural & Large Language Models)

س٩؟

ما هو Attention Mechanism؟

هي تقنية تسمح لنموذج الذكاء الاصطناعي بـ "التركيز" على أجزاء محددة من المدخلات (الكلمات) التي لها صلة بالكلمة التي يعالجها حالياً، مع تجاهل المعلومات غير المهمة

س١٠؟

ما الفرق بين RNN و Transformer؟

الشبكات العصبية التكرارية (RNN) هي نوع من الشبكات العصبية الاصطناعية المصممة للتعامل مع البيانات المتسلسلة أو البيانات التي تعتمد على الزمن.

المحول(Transformer):- هو معمارية (Architecture) للشبكات العصبية العميقة، تعتمد بشكل كلي على آلية الانتباه (Attention Mechanism) لمعالجة البيانات المتسلسلة (مثل النصوص).

الفرق بينها

وجه المقارنة	RNN	Transformer
طريقة المعالجة	تسلسلية (كلمة بعد كلمة)	متوازية (كل الكلمات معاً)
التعامل مع النصوص الطويلة	ضعيف (يفقد السياق البعيد)	ممتاز (بفضل آلية الانتباه)
سرعة التدريب	بطيئة	سريعة جداً
ترتيب الكلمات	يعتمد على الترتيب الزمني	يستخدم (Positional Encoding) لتعريف الترتيب

س١١؟

ما هو NER مع مثال؟

هي اختصار Name Entity Recognition وهي الخاصة بالتعرف والتنصيف كلمات هامة في النص (الكيانات) إلى فئات محددة مسبقاً.

مثال:-

"قام أبو خالد في شهر مارس بزيارة شركة جوجل في مدينة دبي".

*** أبو خالد (Person) شخص**

*** مارس (Data) التاريخ**

*** شركة جوجل (Organization) مؤسسة**

*** دبي (Location) موقع جغرافي**

س١٢؟

اشرح POS Tagging.

هو عملية إسناد وسم نحوي (Tag)لكل كلمة في النص بناءً على دورها الوظيفي في الجملة وسياقها. النموذج هنا لا ينظر لمعنى الكلمة فقط، بل لموقعها الإعرابي ووظيفتها (هل هي اسم، فعل، حرف، صفة، إلخ).

أهميتها (مثل Stemming)

1. **تحسين الـStemming**
2. **تحويل النص إلى صوت(TTS)**
3. **استخراج المعلومات**

س١٣؟

ما هو Sentiment Analysis؟

يعرف على انه القدرة علي استخدام النصوص , لاستخلاص معلومات هامة منها , مثل آراء الناس و انطباعاتهم و الرأي العام و التوجه تجاه أمر ما.

س١٤؟

ما هو Overfitting وكيف تعالجه؟

هو ظاهرة تحدث في التعلم الآلي عندما يقوم النموذج بـ "حفظ "بيانات التدريب (Training Data) بدلاً من "فهم "الأنماط العامة والقواعد الكامنة فيها.

س١٥؟

ما الفرق بين Supervised و Unsupervised في NLP؟

وجه المقارنة	Supervised (خاضع للإشراف)	Unsupervised (غير خاضع للإشراف)
البيانات	بيانات مُصنفة (Input + Label)	بيانات خام (Input only)
الهدف	التنبؤ بقيمة أو فئة (Prediction)	اكتشاف أنماط خفية (Pattern Discovery)
التدخل البشري	عالي (لإعداد التصنيفات والبيانات)	منخفض (النموذج يعتمد على الإحصاء)
أمثلة	التصنيف (Classification)	التجميع (Clustering)

💻 القسم الثالث: أسئلة عملية وتحليلية (١٥ سؤال)

قم بعمل Tokenization للجملة:

"الذكاء الاصطناعي يغير العالم"

[3]:
```python
import re

# الجملة المطلوبة
sentence = "الذكاء الاصطناعي يغير العالم"

# التقطيع باستخدام re.findall
# \w+ (الأحرف والأرقام المتصلة) تعني استخراج الكلمات
tokens = re.findall(r"\w+", sentence)

print(f"الجملة الأصلية: {sentence}")
print(f"الناتجة الـ Tokens: {tokens}")
```

```
الجملة الأصلية: الذكاء الاصطناعي يغير العالم
الناتجة الـ Tokens: ['الذكاء', 'الاصطناعي', 'يغير', 'العالم']
```

احذف Stop Words من الجملة:

"أنا أريد أن أتعلم معالجة اللغات الطبيعية"

[4]:
```python
# تحديد قائمة كلمات التوقف يدوياً (لضمان عمل الكود Offline)
stop_words = {"على", "عن", "إلى", "من", "أن", "أنا"}

sentence = "أنا أريد أن أتعلم معالجة اللغات الطبيعية"

# 1. التقطيع (Tokenization)
tokens = sentence.split()

# 2. الحذف (Filtering)
filtered_sentence = [word for word in tokens if word not in stop_words]

print(f"الجملة الأصلية: {sentence}")
print(f"بعد حذف كلمات التوقف: {filtered_sentence}")
```

```
الجملة الأصلية: أنا أريد أن أتعلم معالجة اللغات الطبيعية
بعد حذف كلمات التوقف: ['أريد', 'أتعلم', 'معالجة', 'اللغات', 'الطبيعية']
```

س

إذا ظهرت كلمة في ٥٠ مستند من أصل ١٠٠٠:

احسب IDF تقريبياً

1. المعادلة المستخدمة:

$$IDF(t) = \log\left(\frac{N}{df}\right)$$

حيث أن:

- N: إجمالي عدد المستندات (1000).
- df: عدد المستندات التي ظهرت فيها الكلمة (50).

2. التعويض في المعادلة:

$$IDF = \log\left(\frac{1000}{50}\right)$$

$$IDF = \log(20)$$

3. الحساب التقريبي:

- إذا استخدمنا **اللوغاريتم العشري** ($\log_{10}$) (وهو الشائع في الاختبارات لسهولة حسابه):
  - بما أن $\log(10) = 1$ و $\log(100) = 2$.
  - فإن $\log(20)$ هو تقريباً 1.3.
- إذا استخدمنا **اللوغاريتم الطبيعي** (ln):
  - $\ln(20) \approx 2.99$.

س

احسب Cosine Similarity بين متجهين بسيطين (أعطِ مثال).

1. المفهوم الرياضي

قياس تشابه جيب التمام (Cosine Similarity) لا يعتمد على "طول" المتجهات، بل على الزاوية بينهما. كلما اقتربت الزاوية من الصفر، كان جيب تمامها ($\cos$) يقترب من 1 (تطابق تام).

المعادلة:

$$CosineSimilarity = \frac{A \cdot B}{\|A\|\|B\|}$$

---

2. مثال عملي بسيط

لنفترض أن لدينا متجهين يمثلان كلمتين في فضاء ثنائي الأبعاد ($2D$):

- المتجه الأول $A = [3, 4]$
- المتجه الثاني $B = [1, 2]$

الخطوة الأولى: حساب الضرب النقطي (Dot Product)

نضرب العناصر المتقابلة ونجمعها:

$$A \cdot B = (3 \times 1) + (4 \times 2) = 3 + 8 = 11$$

الخطوة الثانية: حساب معيار (طول) كل متجه (Magnitude)

نستخدم نظرية فيثاغورس:

- $\|A\| = \sqrt{3^2 + 4^2} = \sqrt{9 + 16} = \sqrt{25} = 5$
- $\|B\| = \sqrt{1^2 + 2^2} = \sqrt{1 + 4} = \sqrt{5} \approx 2.24$

الخطوة الثالثة: التعويض في المعادلة النهائية

$$CosineSimilarity = \frac{11}{5 \times 2.24} = \frac{11}{11.2} \approx 0.982$$

س

لديك بيانات نصية:

كيف تحوّلها إلى أرقام؟

لتحويل النصوص الى ارقام نعمل هذه الخطوات

١- **Preprocessing:تنظيف النص وحذف الكلمات الزائدة.**

٢- **Tokenization:تقطيع النص إلى وحدات(Tokens)**

٣- **Vectorization:اختيار النموذج المناسب؛ فإذا أردنا بحثاً بسيطاً نستخدم TF-IDF**

س

صمّم Pipeline لمعالجة النصوص.

مخطط الـ Pipeline لمعالجة النصوص(NLP Pipeline)

يمر النص بست مراحل أساسية ليتحول من "كلام مرسل" إلى "معلومات مهيكلة"

١- جمع البيانات وتنقيتها(Data Acquisition & Cleaning)
٢- المعالجة الأولية(Preprocessing)
٣- التحليل اللغوي(Linguistic Analysis)
٤- التمثيل الرقمي(Vectorization / Embedding)
٥- النمذجة(Modeling / Task Execution)
٦- التقييم والمخرجات((Evaluation & Output)

س
لديك Dataset صغير:
أي نموذج تختار ولماذا؟
لاختيار الأول: النماذج الإحصائية التقليدية(Classical ML)
إذا كانت البيانات صغيرة جداً (مثلاً مئات أو بضعة آلاف من الأسطر)، فإن الخيار الأفضل هو النماذج البسيطة
مثل:

- Naive Bayes: ممتاز جداً لتصنيف النصوص (Sentiment Analysis) لأنه يعتمد على الاحتمالات ولا يحتاج لبيانات ضخمة ليتعلم.
- SVM (Support Vector Machines): قوي جداً في البيانات ذات الأبعاد العالية (High-dimensional)حتى لو كانت العينات قليلة.
- Logistic Regression: نموذج أساسي صلب يعطيك نتائج منطقية وسريعة التفسير.

لماذا؟
١. تجنب الـ Overfitting: النماذج المعقدة) مثل (Deep Learning ستحفظ البيانات ولن تتعلم منها.
٢. السرعة والسهولة :هذه النماذج لا تتطلب موارد حوسبية عالية.(GPUs)
٣. قابلية التفسير(Explainability)

س
لديك Dataset كبير:
ما النموذج الأفضل؟
١- المحولات(Transformers)
٢- التدريب المسبق(Pre-training)
٣- الضبط الدقيق(Fine-tuning)

س
كيف تحسن دقة نموذج تصنيف نصوص؟
١- تحسين جودة البيانات(Data Centric AI)
٢- المعالجة اللغوية المتقدمة(Feature Engineering)
٣- تحسين بنية النموذج(Model Tuning)
٤- استخدام تقنيات الEnsemble (التصويت)

س
كيف تتعامل مع النصوص العربية؟
١- مرحلة التنظيف والتوحيد(Cleaning & Normalization)
٢- التجزئة الصرفية(Morphological Analysis & Tokenization)

٣- لتجذير والاشتقاق(Stemming vs Lemmatization)
٤- التمثيل الرقمي الذكي(Arabic Word Embeddings)

س
صمّم نظام Sentiment Analysis.
الهيكل الهندسي للنظام(Architecture)
١- طبقة جمع البيانات:(Data Ingestion)
٢- طبقة المعالجة المسبقة:(Preprocessing)
٣- طبقة تمثيل البيانات:(Vectorization)
٤- طبقة التصنيف:(Classification)

س
لديك مشكلة Overfitting:
اقترح ٣ حلول
١- زيادة وتنوع البيانات(Data Augmentation & More Data)
٢- التوقف المبكر(Early Stopping)
٣- تقنيات التنظيم والإسقاط(Regularization & Dropout)

س
قارن بين:
Naive Bayes
Logistic Regression

وجه المقارنة	Naive Bayes	Logistic Regression
النوع	Generative (توليدي إحصائي)	Discriminative (تمييزي خطي)
السرعة	سريعة جداً	متوسطة
حجم البيانات	ممتاز للبيانات الصغيرة	أفضل مع البيانات المتوسطة والكبيرة
استقلالية الميزات	يفترض استقلالية الكلمات (ساذج)	لا يفترض الاستقلالية ويعطي أوزان
التطبيق الشائع	تصنيف البريد المزعج (Spam)	تحليل المشاعر (Sentiment Analysis)

سلديك نصوص غير نظيفة:
كيف تنظفها؟
١- إزالة الضجيج العام(Noise Removal)
٢- التنظيف اللغوي(Text Normalization)
٣- المعالجة الهيكلية(Structural Cleaning)
٤- حذف كلمات التوقف(Stop Words Removal)

```
[8]: import re

def clean_arabic_text(text):
    # 1. إزالة التشكيل
    text = re.sub(r"[\u064B-\u0652]", "", text)
    # 2. توحيد الألفات
    text = re.sub(r"[أإآ]", "ا", text)
    # 3. توحيد الهاء والتاء المربوطة
    text = re.sub(r"ة" ,"ه", text)
    # 4. إزالة غير الأحرف العربية
    text = re.sub(r"[^\u0621-\u064A\s]", " ", text)
    # 5. إزالة المسافات الزائدة
    text = re.sub(r"\s+", " ", text).strip()
    return text

print(clean_arabic_text("الذكاءُ الاصطناعيُّ رائعٌ جدًّا!!!"))
# المخرج: الذكاء الاصطناعي رائع جدا
```

```
الذكاء الاصطناعي رائع جدا
```

س

صمّم مشروع NLP كامل (من البداية للنهاية)

١- مرحلة جمع البيانات(Data Acquisition)

٢- مرحلة المعالجة المسبقة(Preprocessing Pipeline)

- **Normalization:توحيد الألفات والتاء المربوطة.**
- **Noise Removal:حذف الروابط، الإيموجي، والتكرارات (مثل "رائعةةة").**
- **Stop Words:حذف كلمات التوقف العربية (في، من، على)**
- **Stemming/Lemmatization:استخدام مكتبة CamelTools:لرد الكلمات لأصولها..**

٣- تمثيل البيانات(Text Vectorization)

- **الطريقة التقليدية TF-IDF :لتحويل الكلمات لأوزان إحصائية.**
- **الطريقة الحديثة Word Embeddings :باستخدام نموذج AraBERTلتحويل النصوص لمتجهات تفهم السياق.**

٤- بناء النموذج(Modeling)

٥- تقييم الأداء(Evaluation)

- **F1-Score:للتأكد من أن النموذج لا ينحاز لفئة معينة.**
- **Confusion Matrix:لرؤية أين يخطئ النموذج (هل يخلط بين المحايد والسلبي؟).**

✍️ **القسم الخامس: أسئلة نظرية متقدمة (١٥ سؤال)**

س

اشرح Subword Tokenization ولماذا هي مهمة.

هي تقنية لتقطيع النص تقع في "المنطقة الوسطى" بين التقطيع بمستوى الكلمة (Word-level) والتقطيع بمستوى الحرف (Character-level). بدلاً من تقسيم النص إلى كلمات كاملة فقط، تقوم هذه الخوارزمية بتقسيم الكلمات النادرة أو المعقدة إلى وحدات أصغر ذات معنى.(Subwords)

أشهر خوارزمياتها:

- **BPE (Byte Pair Encoding):المستخدمة فيGPT**
- **WordPiece:المستخدمة في.BERT**
- **SentencePiece:المستخدمة في نماذج Google مثل T5 وALBERT**

س

ما الفرق بين:

Autoregressive Models

Masked Language Models

١- **Autoregressive Models**

- طريقة العمل :تقرأ النص في اتجاه واحد فقط (عادةً من اليسار إلى اليمين، أو اليمين إلى اليسار في العربية). تتوقع الكلمة التالية بناءً على الكلمات التي سبقتها فقط.
- آلية الانتباه :(Attention) تستخدم ما يسمى بـ Causal Masking؛ أي أن الكلمة الحالية لا يمكنها "رؤية" الكلمات التي تأتي بعدها أثناء التدريب.
- ستخدام :كتابة المقالات، الدردشة الآلية، وتلخيص النصوص.

٢- نماذج اللغة المقنعة(Masked Language Models - MLM)

- طريقة العمل :تقرأ النص في الاتجاهين معاً .(Bidirectional) أثناء التدريب، نقوم بـ "إخفاء" أو "تغطية (Masking) "بعض الكلمات عشوائياً (بنسبة ١٥٪ غالباً)، ونطلب من النموذج التنبؤ بالكلمة المخفية بناءً على السياق الذي قبلها والذي بعدها.
- آلية الانتباه :(Attention) تستخدم Full Self-Attention؛ حيث يمكن لكل كلمة أن ترى كل الكلمات الأخرى في الجملة لفهم العلاقات المعقدة.
- أفضل استخدام :تصنيف النصوص(Sentiment Analysis) ، استخراج الكيانات(NER) ، والإجابة على الأسئلة.

س

اشرح مفهوم Perplexity وكيف يتم استخدامه.

كلمة "Perplexity" تعني لغوياً "الارتباك" أو "الحيرة". في علم معالجة اللغات الطبيعية(NLP) ، هو مقياس لمدى قدرة النموذج اللغوي على توقع عينة من النص.

١- المقارنة بين النماذج :(Benchmarking) إذا كان لدينا نموذجان لغة) مثل نموذج تدرب على "MyLectures"ونموذج عام(، النموذج الذي يعطي Perplexityأقل على بيانات الاختبار هو الأفضل.

٢- مراقبة عملية التدريب :نستخدمه للتأكد من أن النموذج يتعلم قواعد اللغة بشكل صحيح مع مرور الوقت (Epochs).

٣- تقييم جودة النصوص المولدة :يُستخدم أحياناً للتأكد من أن النص الذي ولده الذكاء الاصطناعي "منطقي" ويشبه لغة البشر.

س

ما الفرق بين BLEU و ROUGE بالتفصيل؟

وجه المقارنة	BLEU Score	ROUGE Score
التطبيق الأساسي	الترجمة الآلية (Translation)	تلخيص النصوص (Summarization)
المعيار الرياضي	Precision (الدقة)	Recall (الاستدعاء/التغطية)
الهدف	التأكد من صحة الكلمات المولدة.	التأكد من شمولية المعلومات المستخرجة.
المشكلة	قد يحذف معلومات هامة ويظل عالياً.	قد يولد جملاً ركيكة وتظل درجته عالية.

س

ما هو Self-Attention وكيف يعمل؟

ي اللغات الطبيعية، قيمة الكلمة تتغير حسب جيرانها.

كيف يعمل تقنياً؟(Query, Key, Value)

١- المطلب :(Query - Q) يمثل "ماذا أبحث عنه؟" (الكلمة الحالية التي نريد فهمها).

٢- المفتاح :(Key - K) يمثل "ماذا أقدم؟" (محتوى الكلمات الأخرى في الجملة).

٣- القيمة :(Value - V) يمثل "المعلومة الفعلية" التي سنأخذها إذا وجدنا تطابقاً.

س

ما هي Positional Encoding ولماذا نحتاجها؟

لأن Transformer لا يقرأ النص تسلسليًا مثل RNN، فهو يحتاج طريقة لتمثيل ترتيب الكلمات.

مثال:

"أكل أحمد التفاحة"

"أكلت التفاحة أحمد"

نفس الكلمات لكن المعنى مختلف بسبب الترتيب.

الحل:

إضافة Positional Encoding لكل كلمة حتى يعرف النموذج موقعها.

س

اشرح الفرق بين Encoder و Decoder في Transformer.

يأخذ النص المدخل

يحوله إلى تمثيل غني بالمعلومات

Decoder

يأخذ هذا التمثيل

يولد النص الناتج كلمة بكلمة

مثال في الترجمة:

Encoder: يفهم الجملة العربية

Decoder: يولد الجملة الإنجليزية

س

ما هو Fine-tuning ولماذا هو مهم؟

Fine-tuning يعني أخذ نموذج مدرب مسبقًا مثل BERT أو AraBERT ثم إعادة تدريبه على مهمة محددة.

مثال:
نموذج عام للغة
نعدله ليصنف المشاعر
لماذا مهم؟
أسرع من التدريب من الصفر
يحتاج بيانات أقل
يعطي أداء أعلى

س
ما هو Transfer Learning في NLP؟
هو نقل المعرفة من نموذج تعلم مسبقًا على بيانات كبيرة إلى مهمة جديدة.
مثال:
نموذج تعلم اللغة من ملايين النصوص
نستخدمه في:
تصنيف النص
NER
الترجمة
فائدته:
تقليل الوقت
تقليل البيانات المطلوبة
تحسين الأداء

س
ما هو Zero-shot Learning مع مثال؟
هو أن ينجز النموذج مهمة بدون أن يتدرب عليها مباشرة.
مثال:
تسألين النموذج:
"صنّف هذا النص إلى إيجابي أو سلبي"
حتى لو لم يتم تدريبه تحديدًا على بياناتك.
الفرق:
Zero-shot: بدون أمثلة
Few-shot: مع أمثلة قليلة

س
ما الفرق بين GPT و BERT؟
Autoregressive
يتنبأ بالكلمة التالية
ممتاز في: توليد النص المحادثة الكتابة
BERT
Masked Language Model

يفهم الكلمة من السياق الكامل
ممتاز في: الفهم التصنيف
NER
QA
الخلاصة:
GPT = توليد
BERT = فهم

س
اشرح Seq2Seq Model مع مثال.
هو نموذج يحول تسلسل إلى تسلسل.
مثال:
ترجمة:
Input: " أنا أحب البرمجة"
Output: "I love programming"
يتكون من:
Encoder
Decoder
الاستخدامات: الترجمة التلخيص المحادثة.

س
ما هي التحديات في بناء Chatbot؟
فهم نية المستخدم فهم السياق السابق التعامل مع الغموض دعم اللهجات تقديم إجابات دقيقة التعامل مع الأخطاء الإملائية إدارة الحوار طويل المدى الأمان ومنع الردود الضارة

س
كيف تقيم نموذج NLP؟ (metrics)
حسب المهمة:
Classification
Accuracy
Precision
Recall
F1-score
Language Model
Perplexity
Translation
BLEU
Summarization
ROUGE
NER / Sequence Labeling

Precision / Recall / F1

💻 القسم السادس: أسئلة عملية / تصميم أنظمة (١٥ سؤال)

س

لديك نص طويل:

كيف تقوم بتلخيصه باستخدام NLP؟

الخطوات:

تنظيف النص تقسيمه إلى جمل استخدام نموذج تلخيص:

Extractive

Abstractive

تقييم الناتج بـ ROUGE

النماذج:

T5

BART

PEGASUS

س

صمّم نظام ترجمة آلية بسيط.

جمع جمل مترجمة تنظيف النصTokenization استخدام Seq2Seq أو Transformer تدريب النموذج

تقييمه بـ BLEU نشر النظام

س

لديك بيانات متعددة اللغات:

كيف تتعامل معها؟

تحديد اللغة أولًا توحيد التنسيق استخدام نماذج متعددة اللغات مثل:

mBERT

XLM-R أو تدريب نموذج لكل لغة

س

كيف تبني Chatbot ذكي؟

Intent Detection

Entity Extraction

Dialogue Management

Response Generation

Memory / Context

يمكن بناؤه باستخدام:

قواعد بسيطة

أو LLM / Transformer

س

لديك مشكلة Ambiguity في النص:
كيف تعالجها؟

الحل:
استخدام السياق استخدام Transformer
Word Sense Disambiguationالاستفادة من الجملة كاملة بدل الكلمة وحدها
مثال:
"عين" قد تعني: عضو في الجسم نبع ماء جاسوس

س
كيف تتعامل مع Out-of-Vocabulary words؟

الحلول:
Subword Tokenization
Character-level models
استخدام BPE / WordPiece
تحديث القاموس إذا لزم

س
لديك Dataset غير متوازن:
كيف تعالجه؟

الحلول:
Subword Tokenization
Character-level models
استخدام BPE / WordPiece
تحديث القاموس إذا لزم

س
كيف تبني نظام NER باستخدام Deep Learning؟

جمع بيانات موسومة
Tokenization
تمثيل الكلمات بـ Embeddings
استخدام نموذج:
BiLSTM + CRF
أو BERT
تدريب النموذج
تقييمه بـ Precision / Recall / F1

س
كيف تستخدم Transformer في مشروعك؟
في مشروع تصنيف مشاعر:
استخدم BERT / AraBERT مرر النص إلى النموذج
Fine-tuningعلى بياناتك التنبؤ بالفئة

س
كيف تختار بين:
BERT
GPT
حسب المهمة؟
اختار BERT إذا كانت المهمة:
Classification
NER
QA
فهم النص
اختار GPT إذا كانت المهمة:
توليد نص
Chatbot كتابة / تلخيص / إكمال قاعدة سهلة للحفظ:
BERT = Understand
GPT = Generate

س
لديك نصوص noisy:
كيف تنظفها؟
(advanced level) إزالة HTML إزالة الروابط إزالة mentions / hashtags حسب المهمة تصحيح التكرار توحيد الترميز إزالة التشكيل إزالة الرموز الغريبة تصحيح الأخطاء الإملائية (اختياري) التعامل مع الإيموجي حسب المهمة

س
كيف تحسن سرعة inference لنموذج NLP؟
استخدام نموذج أصغر
Quantization
Distillation
تقليل طول الإدخال
Batch inference
استخدام GPU/TPU

س
صمّم نظام Question Answering.
الخطوات:
استقبال السؤال
جلب المستندات ذات الصلة
تمرير السؤال + النص إلى نموذج QA
استخراج الإجابة
النماذج:
BERT QA
Retrieval + Reader

س
كيف تبني نظام Text Summarization؟
نوعان:
Extractive
اختيار أهم الجمل
Abstractive توليد ملخص جديد
الخطوات:
تنظيف النص تقطيعه استخدام نموذج:
BART
T5 تقييمه بـ ROUGE

س
صمّم نظام NLP متكامل لشركة (مثلاً بنك أو خدمة عملاء)
تصنيف طلب العميل
استخراج البيانات المهمة (اسم، رقم طلب)
الرد الآلي تحليل مشاعر العميل تلخيص المحادثات تحويل الحالات الصعبة للموظف
التقنيات:
Intent Classification

NER
Sentiment Analysis
Chatbot
Summarization